




**Institut de Formation et de
Recherche en Informatique**



**Benin Workshop on
Artificial Intelligence**



**Université d'Abomey-
Calavi**


Créez votre chatbot documentaire avec le RAG

18 novembre 2025

Ing. Sèdofi Hope LANMAYIKPOHOUE

Sommaire

- 1 Introduction
- 2 Architecture RAG
- 3 Les six étapes du RAG
- 4 Techniques avancées
- 5 Mise en pratique



De 0 à chatbot
fonctionnel



Introduction

Les limites des LLM classiques



Connaissance figée

Données limitées à leur date d'entraînement.



Données limitées

Ne connaissent que ce sur quoi ils ont été entraînés.



Hallucinations

Inventent des informations lorsqu'ils ne savent pas.



Pas d'accès privé

Impossible d'accéder aux données internes (données d'entreprise par exemple).

Qu'est-ce que le RAG ?

Retrieval-Augmented Generation

1

RETRIEVE

Chercher l'information pertinente.

2

AUGMENT

Enrichir le prompt avec le contexte.

3

GENERATE

Produire la réponse finale.



Recherche
Augmentation
Génération

RAG vs. Fine-tuning

Fine-tuning

Prendre un LLM pré-entraîné sur un vaste corpus de texte et l'entraîner davantage sur un ensemble de données plus restreint et plus spécifique à une tâche donnée.

RAG

Combine un LLM avec un mécanisme de recherche d'informations.

RAG

- ✓ Moins cher
- ✓ Données à jour
- ✓ Pas de re-entraînement
- ✗ Dépend de la recherche

Fine-tuning

- ✗ Plus cher
- ✗ Données figées
- ✗ Requiert re-entraînement
- ✓ Meilleure adaptation

Applications pratiques du RAG



Entreprise

KB interne, support client, FAQ RH.



Santé

Recherche dans la littérature médicale.



Juridique

Analyse de la jurisprudence et des lois.



Éducation


Tuteurs intelligents personnalisés.



Architecture RAG

Architecture classique d'un système RAG

Le flux complet de données depuis les documents jusqu'à la réponse générée





Les six étapes du RAG

Les six étapes du RAG

1

Chunking

2

Embeddings

3

Vector Store

4

Retrieval

5

Augmentation

6

Generation

Étape 1 - Préparation des documents

Le chunking



Pourquoi découper ?

Adapter aux limites des modèles et améliorer la précision.




Stratégies

Taille fixe, sémantique, récursif, par document.



Compromis

Taille vs contexte, précision vs couverture.



Transformer le texte en vecteurs qui capturent le sens.



Mots proches en sens = proches dans l'espace.



OpenAI, Google, Sentence Transformers, Word2Vec.

Étape 3 - Stockage et indexation

Les bases de données vectorielles (vector stores)



Cloud

Pinecone

Weaviate

Qdrant



Local

FAISS

ChromaDB

LanceDB



Extensions

pgvector (PostgreSQL)

Redis

Elasticsearch

Étape 4 - Recherche de documents pertinents

Le Retrieval

La recherche se base sur la **similarité cosinus** pour trouver les (k) chunks dont le sens est le plus proche de la question en mesurant l'angle entre les vecteurs.

Hybrid Search

Combine recherche sémantique et par mots-clés.

Metadata Filtering

Filtre les résultats sur des critères (date, source, etc.).

Multi-query

Génère plusieurs variantes de la question pour une recherche plus large.



Étape 5 - Enrichissement du contexte

L'Augmentation (du prompt)

SYSTEM: Définit le comportement du modèle.

Ex : Vous êtes un assistant qui répond en utilisant uniquement le contexte fourni.

CONTEXT: Documents récupérés.

[Chunk 1] Le RAG est une technique qui...

[Chunk 2] Les embeddings sont des représentations...

[Chunk 3] La similarité cosinus permet de...

QUESTION: Requête de l'utilisateur.

Ex : Comment fonctionne le RAG?

INSTRUCTIONS: Format et contraintes de réponse.

Ex : Répondez de manière concise et citez les sources.

Étape 6 - Génération finale

La Génération (de réponse)

Le LLM reçoit le prompt enrichi et génère une réponse naturelle, fondée sur les faits du contexte.

Modèles populaires

- ✓ Mistral
- ✓ LLaMA
- ✓ Gemini
- ✓ GPT

Avantages

- 🛡 Réponses vérifiables
- 📍 Traçabilité complète
- 🚫 Moindres hallucinations
- 🗄 Basé sur des données réelles



Techniques avancées

Techniques avancées



Re-ranking



Multi-query



Grading

Techniques avancées - Re-ranking

Optimiser l'ordre des résultats

Le re-ranking affine les résultats du retrieval avec un modèle précis (ex. : cross-encoder) afin d'améliorer la pertinence des chunks sélectionnés avant l'augmentation du prompt.

Avant : Résultats bruts

Doc 1 (Score: 0.95)

Doc 2 (Score: 0.80)

Doc 3 (Score: 0.75)

Doc 4 (Score: 0.70)



Après : Résultats ré-ordonnancés


Doc 2 (Score: 0.98)

Doc 1 (Score: 0.95)

Doc 4 (Score: 0.60)

Doc 3 (Score: 0.55)

Techniques avancées - Multi-query



Maximiser la couverture



Reformulations multiples

Génère plusieurs variantes de la question



Recherches parallèles

Exécute plusieurs recherches simultanément



Fusion intelligente

Combine les résultats pour un contexte complet

Exemple :

Question : "Comment améliorer la RAG?"

Variantes : "Quelles sont les techniques de RAG avancées ?", "Optimisation RAG", "Meilleures pratiques pour un pipeline RAG".

Techniques avancées - Document grading

Filtrer la qualité

Un filtre pour évaluer la pertinence des documents récupérés avant de les envoyer au LLM.



Évaluation de pertinence

Score chaque document retrouvé




Seuil minimum

Filtre les documents non pertinents



Validation préventive

Évite la pollution du contexte



05 Mise en pratique

Décisions architecturales clés

Les paramètres qui impactent la performance



Taille des chunks

Petit



Grand

512-1024 tokens : l'équilibre idéal.



Nombre de résultats K

Précis



Complet

4-8 documents : bonne couverture.



Overlap entre chunks

Aucun



Important

10-20% : préserve la continuité.



Modèle d'embedding

Général



Spécialisé

Domaine spécifique = meilleure qualité.

Pièges courants et solutions

Éviter les écueils pour réussir

Lost in the middle

L'information importante est enterrée dans le contexte.

Solution : Placer les docs les plus pertinents en début/fin.

Limites de contexte

Dépasser la limite du modèle.

Solution : Chunking intelligent et sélection pertinente.

Qualité variable

Sources de qualité inégale.

Solution : Filtrage et grading des documents.

Similarité superficielle

Mêmes mots, sens différent

Solution : Embeddings de domaine + re-ranking.

Questions ?



Prêts à construire votre chatbot ?

THANKS

Hope